

**ANALISIS *SURVIVAL* MODEL PADA PELANGGAN
TELCO MENGGUNAKAN KAPLAN-MEIER DAN COX
REGRESSION**



Intelligentia - Dignitas

Oleh:

Hanna Zahra Nadia

1305622038

**PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI JAKARTA**

2025

BAB I

PENDAHULUAN

A. Latar Belakang

Dalam beberapa dekade terakhir, Perusahaan telekomunikasi semakin berkembang di Indonesia. industri telekomunikasi menjadi salah satu sektor yang berkembang pesat seiring dengan meningkatnya kebutuhan masyarakat akan akses internet, layanan seluler, dan komunikasi berbasis data. Perusahaan penyedia layanan telekomunikasi berlomba-lomba menawarkan berbagai paket menarik untuk menarik dan mempertahankan pelanggan (Arina & Ulfah, 2022). Namun, di tengah tingginya kompetisi dan pilihan layanan yang semakin beragam, perusahaan menghadapi tantangan besar berupa fenomena *customer churn*, yaitu kondisi ketika pelanggan memilih untuk berhenti berlangganan suatu layanan (Iskandar & Latifa, 2023).

Permasalahan khusus yang muncul adalah ketidakmampuan perusahaan untuk secara akurat memprediksi kapan dan mengapa pelanggan akan berhenti berlangganan. *Customer churn* tidak hanya menyebabkan penurunan pendapatan, tetapi juga meningkatkan biaya akuisisi pelanggan baru. Oleh karena itu, memahami faktor-faktor yang memengaruhi keputusan pelanggan untuk berhenti, serta memperkirakan kapan keputusan tersebut terjadi, menjadi hal yang sangat penting untuk strategi retensi pelanggan (Yulianti, 2018).

Di sisi lain, masih terdapat kesenjangan dalam pemanfaatan pendekatan matematis dan statistik lanjutan untuk menganalisis perilaku *churn* secara komprehensif. Banyak penelitian masih terbatas pada pendekatan klasifikasi sederhana seperti *decision tree* atau *logistic regression* (Dalvi et al., 2016) yang hanya memprediksi kemungkinan *churn* tanpa mempertimbangkan aspek waktu. Padahal, analisis *survival* memungkinkan tidak hanya untuk mengetahui siapa yang kemungkinan akan *churn*, tetapi juga kapan *churn* tersebut terjadi, serta faktor apa saja yang memengaruhi durasi loyalitas pelanggan.

Salah satu pendekatan yang efektif dalam menganalisis kapan pelanggan cenderung melakukan *churn* adalah menggunakan analisis *survival*. *Survival analysis* awalnya banyak digunakan di bidang medis untuk mempelajari waktu bertahan hidup pasien (Dewi et al., 2020), namun kini telah banyak diadopsi dalam bidang lain, termasuk industri, keuangan, dan pemasaran. Dalam konteks ini,

"kematian" dimaknai sebagai kejadian *churn*, dan "waktu bertahan hidup" merujuk pada lamanya seorang pelanggan tetap menggunakan layanan.

Dua metode utama dalam *survival analysis* yang sering digunakan adalah Kaplan-Meier estimator dan *Cox Proportional Hazards* model. Kaplan-Meier estimator digunakan untuk memperkirakan fungsi *survival* dari data yang mengandung *censoring*. Metode ini mampu menggambarkan probabilitas bertahanannya pelanggan dalam waktu tertentu, tanpa mengasumsikan bentuk distribusi tertentu. Visualisasi kurva Kaplan-Meier memungkinkan perusahaan untuk melihat perbedaan tingkat *churn* berdasarkan kelompok, misalnya berdasarkan jenis kontrak atau metode pembayaran. Sementara itu, *Cox Proportional Hazards model* (CoxPH) mampu menganalisis pengaruh variabel-variabel independen terhadap risiko terjadinya peristiwa (dalam hal ini, *churn*) dalam satuan waktu. Model ini memperhitungkan *hazard ratio*—kemungkinan terjadinya *churn* pada waktu tertentu—dengan tetap mempertimbangkan variabel lain. Kelebihan dari CoxPH adalah kemampuannya untuk mengukur efek kovariat secara langsung tanpa perlu mengasumsikan bentuk fungsi dasar dari *hazard* (Amrillah et al., 2024).

Sebagai bentuk penerapan praktis, solusi dalam penelitian ini dibangun menggunakan bahasa pemrograman Python, yang telah menjadi standar de facto dalam bidang data science dan statistik. Dengan memanfaatkan pustaka seperti *lifelines* untuk pemodelan *survival* dan *pandas* untuk manipulasi data, analisis dapat dilakukan secara efisien dan fleksibel terhadap dataset pelanggan dalam jumlah besar. Pendekatan ini memungkinkan integrasi antara teori statistik dan kebutuhan industri secara langsung melalui otomasi dan visualisasi data yang kuat.

Karena itu, penulis tertarik untuk mengkaji penerapan metode Kaplan-Meier dan *Cox Proportional Hazards* dalam menganalisis perilaku *churn* pelanggan pada layanan telekomunikasi. Dengan memanfaatkan data pelanggan secara historis dan mengembangkan solusi berbasis Python, diharapkan penelitian ini dapat memberikan wawasan kuantitatif mengenai faktor-faktor penting yang memengaruhi loyalitas pelanggan, serta membantu perusahaan dalam merancang strategi retensi yang lebih efektif.

B. Rumusan Masalah

1. Bagaimana bentuk fungsi *survival* pelanggan layanan telekomunikasi berdasarkan data historis yang tersedia?
2. Sejauh mana metode Kaplan-Meier dan CoxPH dapat digunakan untuk memodelkan perilaku *churn* pelanggan secara tepat?
3. Faktor-faktor apa saja yang memengaruhi kemungkinan terjadinya *churn* pelanggan?
4. Bagaimana implementasi pemodelan tersebut dapat dilakukan secara praktis menggunakan bahasa pemrograman Python?

C. Tujuan Penelitian

1. Mengestimasi peluang bertahanya pelanggan pada layanan telekomunikasi seiring waktu menggunakan model Kaplan-Meier.
2. Membangun model *Cox Proportional Hazards* untuk menganalisis pengaruh kovariat terhadap risiko *churn*.
3. Mengidentifikasi faktor-faktor seperti biaya bulanan, jenis kontrak, dan metode pembayaran yang memengaruhi risiko pelanggan berhenti berlangganan (*churn*).
4. Mengembangkan solusi analisis *churn* pelanggan berbasis Python yang dapat digunakan sebagai dasar dalam pengambilan keputusan strategis perusahaan.

BAB II

KAJIAN TEORI

A. *Customer churn*

Customer churn adalah situasi ketika pelanggan berhenti menggunakan layanan atau produk dari sebuah perusahaan atau beralih ke kompetitor. Kondisi ini dapat terjadi karena berbagai alasan, seperti ketidakpuasan terhadap layanan, tawaran yang lebih menarik dari pesaing, atau perubahan preferensi pelanggan. Oleh karena itu, penting bagi perusahaan untuk memahami dan memprediksi *churn* agar dapat mengambil langkah strategis dalam mempertahankan pelanggan yang dimiliki (Iskandar & Latifa, 2023).

B. *Analisis Survival*

Analisis survival atau *survival analysis* merupakan cabang statistik yang digunakan untuk menganalisis data waktu yang dibutuhkan sampai terjadinya suatu peristiwa tertentu, misalnya waktu sampai pelanggan berhenti berlangganan (*churn*), waktu bertahan hidup pasien, atau waktu kerusakan mesin. Karakteristik utama dari analisis *survival* adalah adanya kemungkinan data tersensor (*censored*), yaitu data di mana waktu kejadiannya tidak diketahui secara pasti, tetapi diketahui melewati waktu tertentu (Suhartono et al., 2013).

Fungsi *Survival* $S(t)$

Fungsi *survival* menyatakan probabilitas bahwa individu bertahan lebih lama dari waktu t , yaitu:

$$S(t) = P(T > t)$$

di mana:

- T adalah variabel acak yang menyatakan waktu hingga kejadian,
- t adalah waktu tertentu,
- $S(0) = 1$ dan $S(t)$ bersifat monoton menurun terhadap t .

Fungsi *Hazard* $h(t)$

Fungsi *hazard* atau *hazard rate* menyatakan tingkat risiko kegagalan atau terjadinya kejadian pada waktu t , dengan asumsi bahwa individu telah bertahan hingga saat itu. Fungsi ini didefinisikan sebagai:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)}$$

di mana:

- $f(t)$ adalah fungsi densitas probabilitas dari T ,
- $S(t)$ adalah fungsi *survival*.

Fungsi Cumulative Hazard $H(t)$

Fungsi *cumulative hazard* menyatakan akumulasi risiko hingga waktu t , dan didefinisikan sebagai:

$$H(t) = \int_0^t h(u) du$$

Terdapat hubungan antara fungsi *survival* dan *cumulative hazard*:

$$S(t) = e^{-H(t)}$$

Right Censoring

Dalam banyak studi *survival*, tidak semua objek mengalami kejadian selama periode pengamatan. Jika objek masih bertahan pada akhir pengamatan, maka waktu kejadian hanya diketahui lebih dari t , ini disebut *right censored*.

Contoh: Seorang pelanggan masih aktif menggunakan layanan pada akhir periode studi maka kita tahu dia belum berhenti, tapi tidak tahu kapan akan berhenti.

C. Metode Kaplan-Meier

Estimator Kaplan-Meier merupakan metode statistik non-parametrik yang digunakan untuk menghitung fungsi *survival* tanpa memerlukan asumsi distribusi tertentu. Dalam penerapannya, metode ini menghitung peluang terjadinya suatu peristiwa pada waktu tertentu, lalu peluang tersebut dikalikan secara berurutan dengan peluang dari waktu sebelumnya untuk memperoleh estimasi akhir. Hasil dari estimasi Kaplan-Meier dapat digunakan untuk membandingkan tingkat kelangsungan hidup antar kelompok, guna mengetahui apakah terdapat perbedaan yang signifikan (Amrillah et al., 2024). Visualisasi Kaplan-Meier berbentuk kurva tangga yang menurun seiring berjalannya waktu. Estimator ini sangat berguna untuk menggambarkan pola *survival* secara keseluruhan dan membandingkan dua atau lebih kelompok tanpa mempertimbangkan variabel kovariat.

Kaplan-Meier digunakan untuk mengestimasi *survival function* tanpa melibatkan prediktor. Ini menghitung probabilitas bertahan pelanggan pada waktu tertentu (misalnya, berapa persen pelanggan yang masih berlangganan setelah 6 bulan, 12 bulan, dst).

Bentuk model Kaplan-Meier:

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

di mana:

- $\hat{S}(t)$: estimasi probabilitas bertahan hingga waktu t
- t_i : waktu ketika terjadi kejadian (*churn*)
- d_i : jumlah pelanggan yang berhenti pada waktu t_i
- n_i : jumlah pelanggan yang masih bertahan sebelum waktu t_i

D. Model Cox Proportional Hazards

Regresi proporsional *hazard* Cox (*Cox's proportional hazard regression*), atau yang lebih dikenal sebagai Regresi Cox, merupakan metode yang digunakan untuk memodelkan data waktu-ke-kejadian (*time-to-event*), termasuk ketika terdapat kasus yang tersensor. Regresi Cox mampu menangani data tersensor dengan tepat dan menghasilkan estimasi koefisien untuk setiap kovariat, sehingga memungkinkan kita untuk menilai pengaruh berbagai kovariat dalam satu model. Metode ini juga dapat digunakan untuk memperkirakan pengaruh dari kovariat kontinu.

Model *hazard* proporsional tidak mengasumsikan bentuk atau sifat tertentu dari distribusi *survival* yang mendasari. Satu-satunya asumsi model ini adalah bahwa risiko (*hazard*) kematian pada waktu tertentu untuk individu dalam satu kelompok bersifat proporsional terhadap risiko pada waktu yang sama untuk individu yang sebanding di kelompok lain. Jika fungsi *hazard* antara dua kelompok bersifat proporsional, maka kurva *survival* dari kedua kelompok tidak akan saling berpotongan (Collett, 2023).

Cox regression digunakan untuk melihat pengaruh variabel prediktor terhadap waktu bertahan pelanggan. Misalnya, apakah pelanggan dengan metode pembayaran tertentu lebih cepat berhenti, atau pelanggan dengan kontrak tahunan bertahan lebih lama.

Bentuk model:

$$h(t|X) = h_0(t) \cdot e^{\beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p}$$

di mana:

- $h(t|X)$: fungsi *hazard* (risiko berhenti) pada waktu t dengan karakteristik X
- $h_0(t)$: baseline *hazard*, risiko dasar saat semua $X = 0$

- $\beta_1, \beta_2, \dots, \beta_p$: koefisien yang menunjukkan seberapa besar pengaruh setiap variabel
- $X_1, X_2, \dots, X_p$: variabel prediktor (seperti Contract, PaymentMethod, MonthlyCharges)

Model ini memungkinkan analisis multivariat dan mendalam terhadap faktor-faktor yang mempengaruhi kejadian.

E. Aplikasi Python dalam Analisis *Survival*

Dalam era data science modern, Python menjadi salah satu bahasa pemrograman yang sangat populer untuk analisis statistik, termasuk *survival analysis*. Dengan pustaka-pustaka yang kuat seperti lifelines, pandas, dan matplotlib, Python memungkinkan pengguna untuk melakukan estimasi model *survival* secara komputasional dan visual secara efisien.

Bahasa pemrograman Python menawarkan berbagai pustaka (library) untuk melakukan analisis *survival*, salah satunya adalah lifelines. Library ini menyediakan fungsi untuk membangun Kaplan-Meier estimator dan Cox model, serta menampilkan kurva *survival* dan fungsi *hazard*.

Contoh kode dasar:

```

1  from lifelines import KaplanMeierFitter, CoxPHFitter
2
3  # Kaplan-Meier
4  kmf = KaplanMeierFitter()
5  kmf.fit(durations=df['tenure'], event_observed=df['Churn'])
6  kmf.plot_survival_function()
7
8  # Cox PH
9  cph = CoxPHFitter()
10 cph.fit(df_model, duration_col='tenure', event_col='Churn')
11 cph.print_summary()
```

Kode pada Kaplan-Meier melakukan *fitting* model Kaplan-Meier dan memvisualisasikan *survival curve* untuk durasi tenure dengan status kejadian *Churn*. Kurva ini menggambarkan probabilitas pelanggan tetap berlangganan seiring waktu.

Sedangkan pada kode Cox PH, Model ini memberikan estimasi *hazard ratio* untuk setiap variabel prediktor. Nilai $\exp(\text{coef})$ menunjukkan seberapa besar pengaruh variabel tersebut terhadap risiko *churn*. Misalnya, nilai di atas 1 berarti meningkatkan risiko, sedangkan di bawah 1 berarti menurunkan risiko.

BAB III

METODE PENELITIAN

Penelitian ini merupakan penelitian kuantitatif deskriptif yang bertujuan untuk menganalisis kemungkinan pelanggan berhenti berlangganan (*churn*) berdasarkan variabel-variabel tertentu dengan menggunakan metode analisis *survival*.

Data yang digunakan merupakan data sekunder yang diperoleh dari situs Kaggle dengan judul *Telco Customer churn*. Dataset ini berisi informasi mengenai pelanggan sebuah perusahaan telekomunikasi, termasuk status *churn*, durasi berlangganan, serta variabel demografis dan layanan yang digunakan. Dataset terdiri dari sekitar 7.043 entri pelanggan dengan lebih dari 20 variabel.

Pengumpulan data dilakukan dengan cara mengunduh dataset secara langsung dari Kaggle. Dataset kemudian dibersihkan dan diproses untuk keperluan analisis lebih lanjut, termasuk penanganan data kosong dan pengkodean variabel kategorik.

Populasi dalam penelitian ini adalah seluruh pelanggan dalam dataset. Karena seluruh data digunakan dalam analisis, maka penelitian ini menggunakan total sampling.

Data dianalisis menggunakan metode Kaplan-Meier untuk melihat fungsi *survival* berdasarkan waktu pelanggan bertahan, serta *Cox Proportional Hazards model* untuk mengidentifikasi faktor-faktor yang berpengaruh terhadap risiko *churn*. Proses analisis dilakukan dengan menggunakan bahasa pemrograman Python, khususnya pustaka *lifelines*, *pandas*, dan *matplotlib*.

Berikut ini langkah-langkah proses analisis yang dilakukan.

1. Import Dataset
2. Pembersihan Data (*Data Cleaning*)
3. Definisi Variabel *Survival*
4. Analisis Kaplan-Meier
5. Analisis *Cox Proportional Hazards*
6. Visualisasi Hasil
7. Kesimpulan

BAB IV

PEMBAHASAN

A. Langkah-langkah Analisis

Pra-pemrosesan Data

Langkah pertama dalam analisis *survival* adalah memuat dan mempersiapkan data dengan benar. Pada tahap ini, dilakukan penghapusan data kosong khususnya pada kolom *TotalCharges* yang memiliki nilai hilang. Hal ini penting untuk memastikan bahwa model tidak terganggu oleh ketidakterisian data. Selanjutnya, kolom-kolom yang bersifat kategorikal diubah ke dalam bentuk numerik melalui teknik *one-hot encoding* (dummy variables), sehingga dapat digunakan dalam pemodelan matematis. Setelah itu, dilakukan pengecekan ulang agar semua variabel yang akan digunakan dalam model memiliki tipe data numerik, sebagai syarat penting dalam membangun model *survival* seperti Kaplan-Meier dan *Cox Proportional Hazards*.

```
1 import pandas as pd
2 from lifelines import KaplanMeierFitter, CoxPHFitter
3
4 # Load data
5 raw_df = pd.read_csv('Telco-Customer-Churn.csv')
6 raw_df = raw_df[raw_df['TotalCharges'] != ' ']
7 raw_df['TotalCharges'] = raw_df['TotalCharges'].astype(float)
```

Pertama, data dimuat menggunakan fungsi `read_csv` dari pustaka `pandas` untuk membaca file bernama *Telco-Customer-Churn.csv*. Setelah itu, dilakukan pembersihan terhadap kolom *TotalCharges*, karena terdapat nilai kosong yang ditandai dengan spasi (' '). Nilai-nilai ini dihapus agar tidak menyebabkan error saat proses analisis statistik. Kemudian, kolom tersebut dikonversi ke tipe data numerik (`float`) supaya bisa digunakan dalam perhitungan model *survival*.

```
9 # Label encoding
10 raw_df['Churn'] = raw_df['Churn'].apply(lambda x: 1 if x == 'Yes' else 0)
```

Setelah data dibersihkan, langkah berikutnya adalah mengonversi variabel target *Churn* dari tipe kategorikal menjadi numerik. Pada dataset awal, nilai *Churn* berupa string "Yes" dan "No" yang menunjukkan apakah pelanggan berhenti menggunakan layanan atau tidak. Nilai ini tidak bisa langsung digunakan dalam model statistik, sehingga dikonversi menjadi nilai numerik: "Yes" diubah menjadi 1 (menandakan

kejadian *churn* terjadi), sedangkan "No" menjadi 0 (tidak terjadi *churn*). Proses ini dilakukan menggunakan fungsi `apply` dengan lambda *function* untuk menerapkan logika perubahan pada seluruh kolom.

```
11
12 # Feature engineering
13 df = pd.get_dummies(raw_df, columns=['Partner', 'Dependents', 'PhoneService', 'MultipleLines',
14                                     'InternetService', 'OnlineSecurity', 'OnlineBackup',
15                                     'DeviceProtection', 'TechSupport', 'StreamingTV',
16                                     'StreamingMovies', 'PaperlessBilling', 'Contract',
17                                     'PaymentMethod'], drop_first=True)
```

Setelah target variabel *Churn* dikonversi ke bentuk numerik, tahap berikutnya adalah melakukan *feature engineering* dengan mengubah variabel kategorikal lainnya menjadi format yang bisa diterima oleh model statistik, khususnya model *survival analysis*. Hal ini dilakukan dengan teknik yang dikenal sebagai *one-hot encoding* menggunakan fungsi `pd.get_dummies()`. Kolom-kolom seperti *Partner*, *Dependents*, *PhoneService*, *MultipleLines*, *InternetService*, dan lainnya merupakan variabel kategorikal dengan dua atau lebih nilai unik.

Fungsi `pd.get_dummies()` secara otomatis mengubah setiap nilai unik dalam kolom-kolom tersebut menjadi kolom biner tersendiri. Sebagai contoh, kolom *Partner* yang memiliki nilai "Yes" dan "No" akan diubah menjadi satu kolom baru *Partner_Yes* yang berisi 1 jika pelanggan memiliki pasangan, dan 0 jika tidak. Parameter `drop_first=True` digunakan untuk menghindari *dummy variable trap* dengan menghapus satu kategori sebagai referensi, agar tidak terjadi multikolinearitas dalam model.

Hasil dari proses ini adalah data yang seluruhnya numerik, sehingga siap untuk dimasukkan ke dalam model Kaplan-Meier maupun *Cox Proportional Hazards*.

Analisis Kaplan-Meier

Model Kaplan-Meier digunakan untuk mengestimasi fungsi *survival* tanpa mempertimbangkan kovariat. Variabel yang digunakan:

- *Tenure*: durasi pelanggan berlangganan (sebagai waktu observasi)
- *Churn*: status kejadian (1 untuk *churn*, 0 untuk tidak *churn*)

```
3 # Kaplan-Meier
4 kmf = KaplanMeierFitter()
5 kmf.fit(durations=df['tenure'], event_observed=df['Churn'])
6 kmf.plot_survival_function()
```

Hasil visualisasi kurva menunjukkan probabilitas pelanggan tetap berlangganan dari waktu ke waktu. Penurunan kurva *survival* mengindikasikan bahwa semakin lama pelanggan menggunakan layanan, kemungkinan *churn* meningkat, namun tetap ada kelompok yang loyal hingga waktu yang lama.

Analisis Cox Proportional Hazards

Model Cox digunakan untuk mengevaluasi pengaruh kovariat terhadap risiko *churn*. Variabel yang digunakan mencakup faktor-faktor seperti status senior citizen, biaya bulanan dan total biaya, jenis kontrak, dan metode pembayaran.

```
8 # Cox PH
9 cph = CoxPHFitter()
10 cph.fit(df_model, duration_col='tenure', event_col='Churn')
11 cph.print_summary()
```

Hasil yang diperoleh dari `print_summary()` menunjukkan beberapa temuan penting:

- Koefisien positif menunjukkan peningkatan risiko *churn*
- Contract_Two year memiliki koefisien negatif besar, artinya kontrak jangka panjang menurunkan risiko *churn* secara signifikan
- Metode pembayaran Electronic check meningkatkan risiko *churn*


B. Interpretasi Hasil

Fitting Model Kaplan-Meier

Setelah preprocessing data, dilakukan fitting model Kaplan-Meier. Kode implementasi dalam python sebagai berikut:

```
1 from lifelines import KaplanMeierFitter
2 import matplotlib.pyplot as plt
3
4 kmf = KaplanMeierFitter()
5 kmf.fit(durations=df['tenure'], event_observed=df['Churn'])
6
7 kmf.plot_survival_function()
8 plt.title("Kaplan-Meier Survival Curve")
9 plt.xlabel("Tenure (bulan)")
10 plt.ylabel("Probabilitas Bertahan (Survival Probability)")
11 plt.grid()
12 plt.show()
```

Output Grafik



Interpretasi

Grafik di atas merupakan hasil visualisasi dari model Kaplan-Meier yang digunakan untuk mengestimasi probabilitas bertahanannya pelanggan selama periode waktu tertentu, yang dalam hal ini diukur dalam satuan bulan (tenure). Sumbu horizontal (x-axis) menunjukkan lama waktu pelanggan menggunakan layanan (tenure), sedangkan sumbu vertikal (y-axis) menunjukkan probabilitas bertahan atau *survival probability*, yaitu peluang bahwa seorang pelanggan masih tetap menggunakan layanan hingga waktu tertentu.

Dari grafik terlihat bahwa kurva *survival* menurun secara bertahap seiring bertambahnya waktu. Hal ini mengindikasikan bahwa semakin lama pelanggan berada dalam layanan, semakin besar kemungkinan mereka akan berhenti (*churn*). Penurunan tidak terjadi secara tajam melainkan bertahap, yang menunjukkan bahwa tingkat *churn* terjadi secara konsisten sepanjang waktu.

Beberapa poin penting dari grafik ini:

1. Awal Kurva (Tenure 0–10 bulan)

Penurunan tajam pada awal kurva mengindikasikan bahwa sebagian besar pelanggan *churn* terjadi dalam 10 bulan pertama. Ini bisa menunjukkan masa

krusial di mana pelanggan cenderung mengevaluasi layanan dan memutuskan untuk tetap atau berhenti.

2. Setelah 20–30 bulan

Probabilitas bertahan cenderung lebih stabil dan penurunannya lebih lambat. Ini menunjukkan bahwa pelanggan yang berhasil melewati masa awal cenderung lebih loyal dan memiliki risiko *churn* yang lebih rendah.

3. Akhir Kurva (sekitar 70 bulan)

Pada titik ini, *survival* probability mendekati 0.6, artinya hanya sekitar 60% dari pelanggan yang masih bertahan setelah 70 bulan berlangganan.

4. Shaded Area (*Confidence Interval*)

Area biru di sekitar garis kurva menunjukkan *confidence interval* dari estimasi Kaplan-Meier. Semakin lebar area ini, semakin tinggi ketidakpastian estimasi *survival*-nya. Di awal waktu, interval sempit karena data lebih banyak, sedangkan di akhir waktu menjadi lebih lebar karena jumlah data yang tersisa berkurang.

Fitting Model *Cox Proportional Hazards*

Berikut merupakan hasil output yang diperoleh dari penerapan model *Cox Proportional Hazards* menggunakan library *lifelines* di Python. Model ini digunakan untuk menganalisis faktor-faktor yang memengaruhi durasi bertahannya pelanggan (*tenure*) sebelum melakukan *churn* pada data Telco Customer.

```
<lifelines.CoxPHFitter: fitted with 7043 total observations, 5174 right-censored observations>
      duration col = 'tenure'
      event col = 'Churn'
      baseline estimation = breslow
      number of observations = 7043
      number of events observed = 1869
      partial log-likelihood = -12763.85
      time fit was run = 2025-05-11 08:39:41 UTC
```

Informasi Umum Model

- Jumlah observasi: 7043 pelanggan
- Jumlah kejadian (*churn*): 1869
- Jumlah tersensor (tidak *churn*): 5174
- Metode estimasi baseline: *Breslow*
- Concordance: 0.93 → nilai ini sangat tinggi, menandakan bahwa model mampu memprediksi urutan waktu kejadian dengan akurasi sangat baik.

---	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef)	lower 95%	exp(coef)	upper 95%
covariate									
SeniorCitizen	0.13	1.14	0.05	0.02	0.24		1.02		1.27
MonthlyCharges	0.05	1.05	0.00	0.05	0.06		1.05		1.06
TotalCharges	-0.00	1.00	0.00	-0.00	-0.00		1.00		1.00
Contract_One year	-1.67	0.19	0.10	-1.86	-1.48		0.16		0.23
Contract_Two year	-4.43	0.01	0.19	-4.80	-4.07		0.01		0.02
PaymentMethod_Credit card (automatic)	0.03	1.03	0.09	-0.15	0.20		0.86		1.23
PaymentMethod_Electronic check	0.44	1.55	0.07	0.30	0.58		1.35		1.79
PaymentMethod_Mailed check	0.47	1.60	0.09	0.30	0.64		1.35		1.90

	cmp to	z	p	-log2(p)
covariate				
SeniorCitizen	0.00	2.36	0.02	5.76
MonthlyCharges	0.00	34.20	<0.005	849.11
TotalCharges	0.00	-43.12	<0.005	inf
Contract_One year	0.00	-17.16	<0.005	216.79
Contract_Two year	0.00	-23.68	<0.005	409.36
PaymentMethod_Credit card (automatic)	0.00	0.28	0.78	0.36
PaymentMethod_Electronic check	0.00	6.09	<0.005	29.75
PaymentMethod_Mailed check	0.00	5.46	<0.005	24.32

Interpretasi Variabel (Covariates)

Model menampilkan estimasi koefisien (coef) dan *hazard ratio* (exp(coef)), serta nilai signifikansi (p-value).

SeniorCitizen

- exp(coef) = 1.14, artinya pelanggan yang merupakan senior (usia lanjut) memiliki risiko *churn* 14% lebih tinggi dibanding pelanggan yang bukan senior.
- p = 0.02, signifikan secara statistik.

MonthlyCharges

- exp(coef) = 1.05, berarti semakin tinggi tagihan bulanan, semakin besar risiko *churn*. Setiap kenaikan 1 unit dalam tagihan bulanan meningkatkan risiko *churn* sebesar 5%.
- p < 0.005, sangat signifikan.

Artinya, semakin mahal layanan yang dibayar pelanggan, semakin besar kemungkinan mereka berhenti berlangganan.

TotalCharges

- exp(coef) = 1.00, koefisien sangat kecil dan p-value sangat signifikan. Ini menunjukkan bahwa meskipun TotalCharges sedikit berpengaruh, namun secara praktis dampaknya bisa diabaikan atau sangat kecil.

Contract_One year

- exp(coef) = 0.19 artinya pelanggan dengan kontrak satu tahun memiliki risiko *churn* 81% lebih rendah dibanding pelanggan dengan kontrak bulanan (baseline).
- p < 0.005, sangat signifikan.

Contract_Two year

- $\exp(\text{coef}) = 0.01$ artinya pelanggan kontrak dua tahun memiliki risiko *churn* 99% lebih rendah dibanding kontrak bulanan. Ini menunjukkan bahwa kontrak jangka panjang sangat mengurangi kemungkinan *churn*.
- $p < 0.005$, sangat signifikan.

PaymentMethod_Credit card (automatic)

- $\exp(\text{coef}) = 1.03$, menunjukkan hampir tidak ada perbedaan risiko *churn* dibanding metode baseline.
- $p = 0.78$, tidak signifikan.

PaymentMethod_Electronic check

- $\exp(\text{coef}) = 1.55$, menunjukkan pelanggan dengan metode pembayaran electronic check memiliki risiko *churn* 55% lebih tinggi dibanding baseline.
- $p < 0.005$, signifikan.


PaymentMethod_Mailed check

- $\exp(\text{coef}) = 1.60$, berarti risiko *churn* 60% lebih tinggi dibanding metode pembayaran baseline.
- $p < 0.005$, signifikan.

```
Concordance = 0.93
Partial AIC = 25543.70
log-likelihood ratio test = 5778.38 on 8 df
-log2(p) of ll-ratio test = inf
```

Log-likelihood ratio test

nilai sangat tinggi (5778.38), dengan p-value sangat kecil ($\log_2(p) = \text{inf}$), artinya model secara keseluruhan sangat signifikan dan cocok digunakan untuk menjelaskan risiko *churn*.



Gambar di atas menunjukkan visualisasi koefisien model *Cox Proportional Hazards* dalam skala logaritmik *hazard ratio* ($\log(\text{HR})$) beserta interval kepercayaan 95%-nya. Sumbu horizontal merepresentasikan nilai $\log(\text{HR})$, di mana nilai $\log(\text{HR}) > 0$ menunjukkan peningkatan risiko *churn*, sedangkan nilai $\log(\text{HR}) < 0$ menunjukkan penurunan risiko *churn*.

Dari grafik tersebut, terlihat bahwa variabel *Contract_Two year* dan *Contract_One year* memiliki nilai $\log(\text{HR})$ yang paling rendah, yang berarti pelanggan dengan kontrak dua tahun atau satu tahun memiliki risiko *churn* yang jauh lebih rendah dibandingkan pelanggan dengan kontrak bulanan. Sebaliknya, metode pembayaran menggunakan *Electronic check* dan *Mailed check* memiliki nilai $\log(\text{HR})$ positif yang cukup tinggi, yang menunjukkan peningkatan risiko *churn* secara signifikan.

Selain itu, pelanggan yang merupakan *SeniorCitizen* serta yang memiliki *MonthlyCharges* lebih tinggi juga menunjukkan peningkatan risiko *churn*, meskipun dengan $\log(\text{HR})$ yang relatif kecil. Sementara itu, variabel *TotalCharges* dan metode pembayaran *Credit card (automatic)* memiliki nilai $\log(\text{HR})$ yang sangat mendekati nol, sehingga dapat disimpulkan bahwa pengaruh keduanya terhadap risiko *churn* tidak signifikan secara praktis.

Interval kepercayaan (*confidence interval*) yang tidak memotong garis vertikal nol menandakan bahwa koefisien variabel tersebut signifikan secara statistik. Hal ini tampak pada variabel kontrak dan metode pembayaran tertentu, yang mendukung hasil numerik sebelumnya.

BAB V

PENUTUP

A. Kesimpulan

Kaplan-Meier *Survival* Curve menunjukkan bahwa probabilitas pelanggan untuk tetap bertahan menurun seiring bertambahnya durasi berlangganan (*tenure*). Kurva menunjukkan bahwa risiko *churn* meningkat secara bertahap, terutama dalam 12 bulan pertama masa langganan.

Model *Cox Proportional Hazards* berhasil mengidentifikasi beberapa faktor signifikan yang memengaruhi tingkat risiko *churn* pelanggan. Variabel seperti jenis kontrak, metode pembayaran, dan biaya bulanan (*MonthlyCharges*) terbukti memiliki pengaruh yang signifikan terhadap durasi bertahanya pelanggan. Misalnya, pelanggan dengan kontrak dua tahun memiliki *hazard ratio* jauh lebih rendah, yang berarti mereka cenderung lebih lama bertahan dibandingkan pelanggan dengan kontrak bulanan.

Implementasi model *survival analysis* menggunakan Python, khususnya dengan library *lifelines*, terbukti mampu memberikan hasil yang akurat dan interpretatif dalam memodelkan data durasi (*tenure*) serta mengevaluasi pengaruh variabel terhadap risiko kejadian (*churn*). Hal ini menunjukkan bahwa pendekatan berbasis pemrograman memiliki potensi besar dalam pengambilan keputusan berbasis data, terutama di bidang analitik pelanggan.

Daftar Pustaka

- Amrillah, T., Widiyanti, P., Sari, R., Purbandini, P., Awal, L. J., Prastio, R. P., Fakhruzzaman, M. N., Wardana, A. A., & Jiwanti, P. K. (2024). *Proceedings of the International Conference on Advanced Technology and Multidiscipline (ICATAM 2024)*. Springer Nature.
- Arina, F., & Ulfah, M. (2022). Analisa *survival* untuk mengurangi *customer churn* pada perusahaan telekomunikasi. *Journal Industrial Servicess*, 8(1), 59.
<https://doi.org/10.36055/jiss.v8i1.14313>
- Collett, D. (2023). *Modelling Survival Data in Medical Research* (4th ed.). Chapman and Hall/CRC. <https://doi.org/10.1201/9781003282525>
- Dalvi, P. K., Khandge, S. K., Deomore, A., Bankar, A., & Kanade, V. A. (2016). Analysis of *customer churn* prediction in telecom industry using decision trees and logistic regression. *2016 Symposium on Colossal Data Analysis and Networking (CDAN)*, 1–4. <https://doi.org/10.1109/CDAN.2016.7570883>
- Dewi, A. Y., Dwidayati, N. K., & Agoestanto, A. (2020). ANALISIS *SURVIVAL* MODEL REGRESI COX DENGAN METODE MLE UNTUK PENDERITA DIABETES MELLITUS. *Unnes Journal of Mathematics*, 9(1), Article 1.
<https://doi.org/10.15294/ujm.v9i1.30559>
- Iskandar, M. A., & Latifa, U. (2023). WEBSITE PREDIKSI *CUSTOMER CHURN* UNTUK MEMPERTAHANKAN PELANGGAN PADA PERUSAHAAN TELEKOMUNIKASI. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 7(2), Article 2.
<https://doi.org/10.36040/jati.v7i2.6639>
- Suhartono, D., Saefuddin, A., & Sumertajaya, I. M. (2013). *SURVIVAL ANALYSIS OF CUSTOMER IN POSTPAID TELECOMMUNICATION INDUSTRY. FORUM STATISTIKA DAN KOMPUTASI*, 18(1), Article 1.
<https://journal.ipb.ac.id/index.php/statistika/article/view/12315>
- Telco Customer churn*. (n.d.). Retrieved May 11, 2025, from <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- Yulianti, Â. (2018). Metode Data mining Untuk prediksi *Churn* Pelanggan. *Journal ICT*, 9(16).